

HIGH RESOLUTION FACE AGE EDITING

Yao et al, 2020

Matheus Levi, 25 de julho de 2024

SUMÁRIO

Introdução

01

Trabalhos
Relacionados

02

Modelo
Proposto

03

Resultados

04

Discussão

05

Conclusão

06

INTRODUÇÃO



MOTIVAÇÕES E OBJETIVOS

- ◆ Pós-produção de filmes e fotografia em geral
- ◆ Criar um método que não produza artefatos visuais ao editar as imagens
- ◆ Obter imagens realistas de uma mesma pessoa em idades diferentes

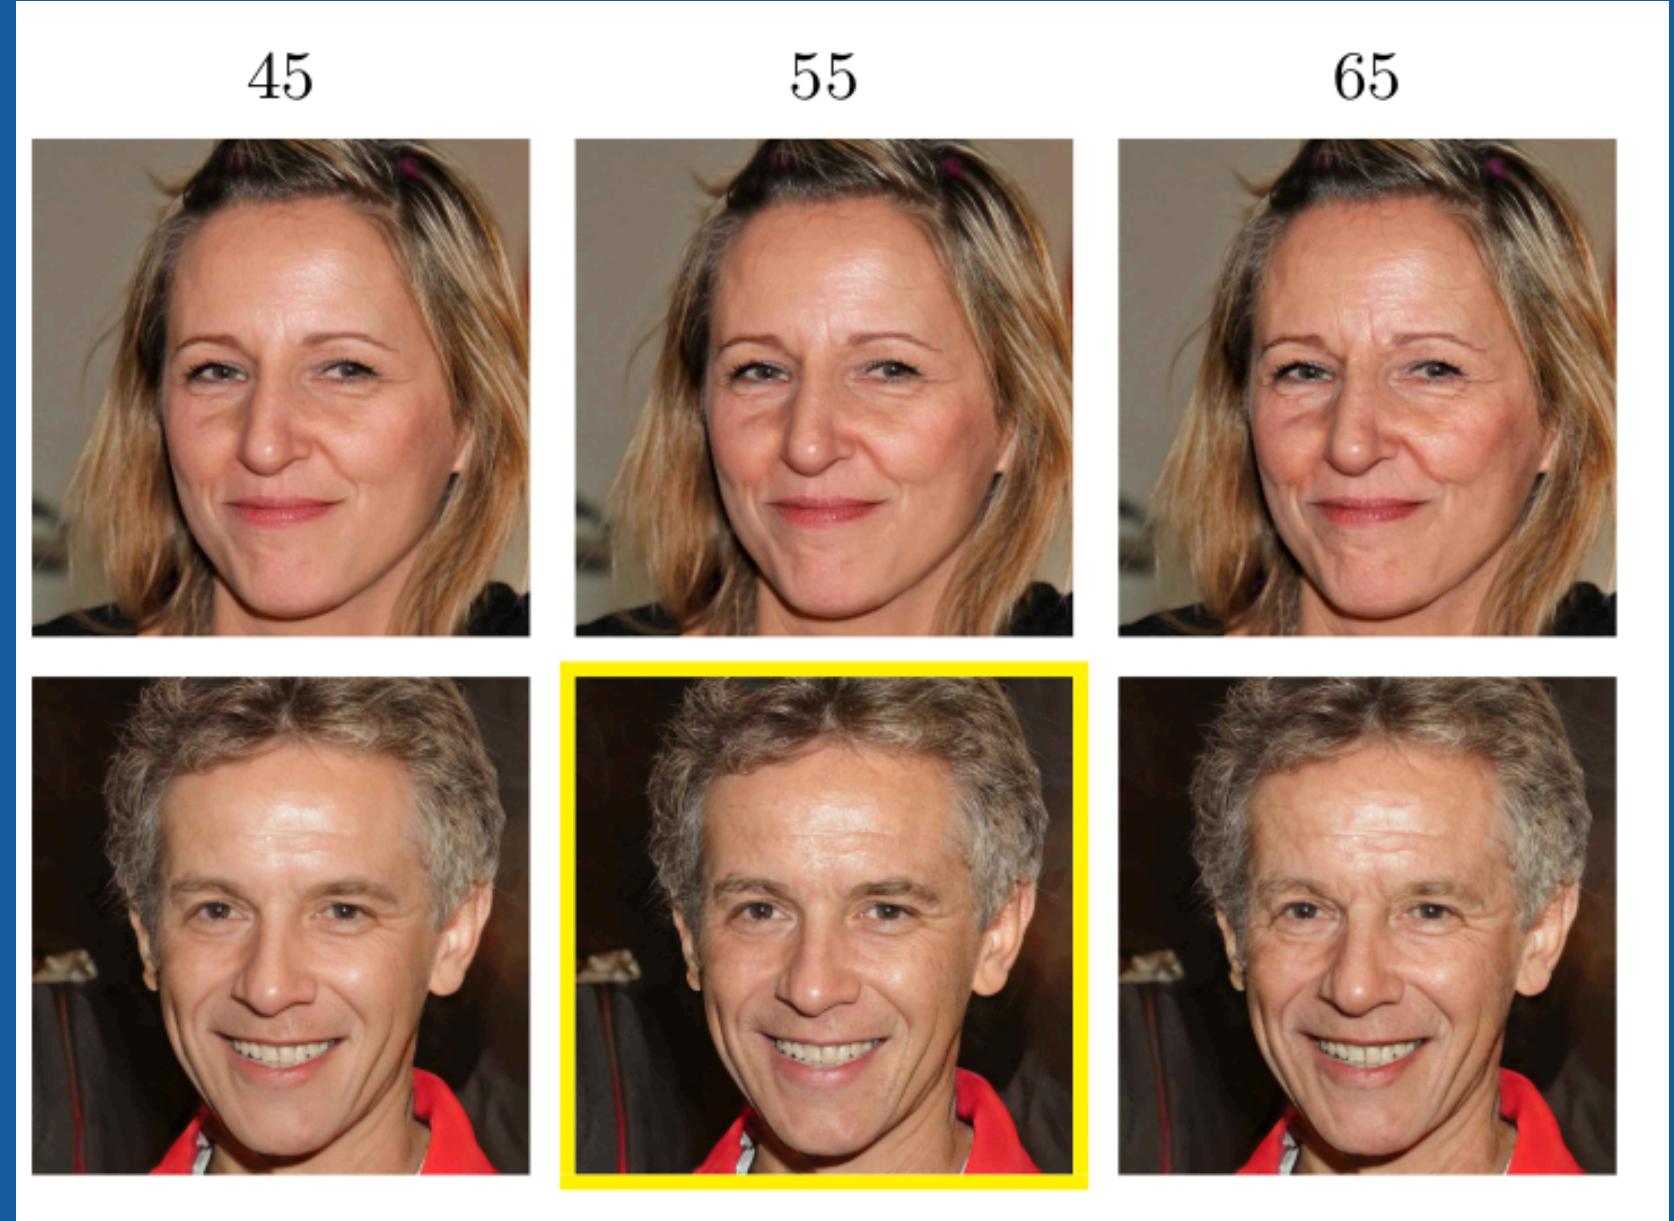


Fig. 1: Exemplos de imagens do modelo

TRABALHOS RELACIONADOS



AGE TRANSFORMATION

- ◆ Muitos trabalhos utilizam conditional GAN's
- ◆ Normalmente a transformação é feita entre **grupos de idades**
- ◆ Preservação de identidade tem melhorado, mas acaba criando imagens ultra-suavizadas
- ◆ Modelos baseados em Wavelet capturam detalhes de textura bem, mas introduzem **fortes artefatos visuais**

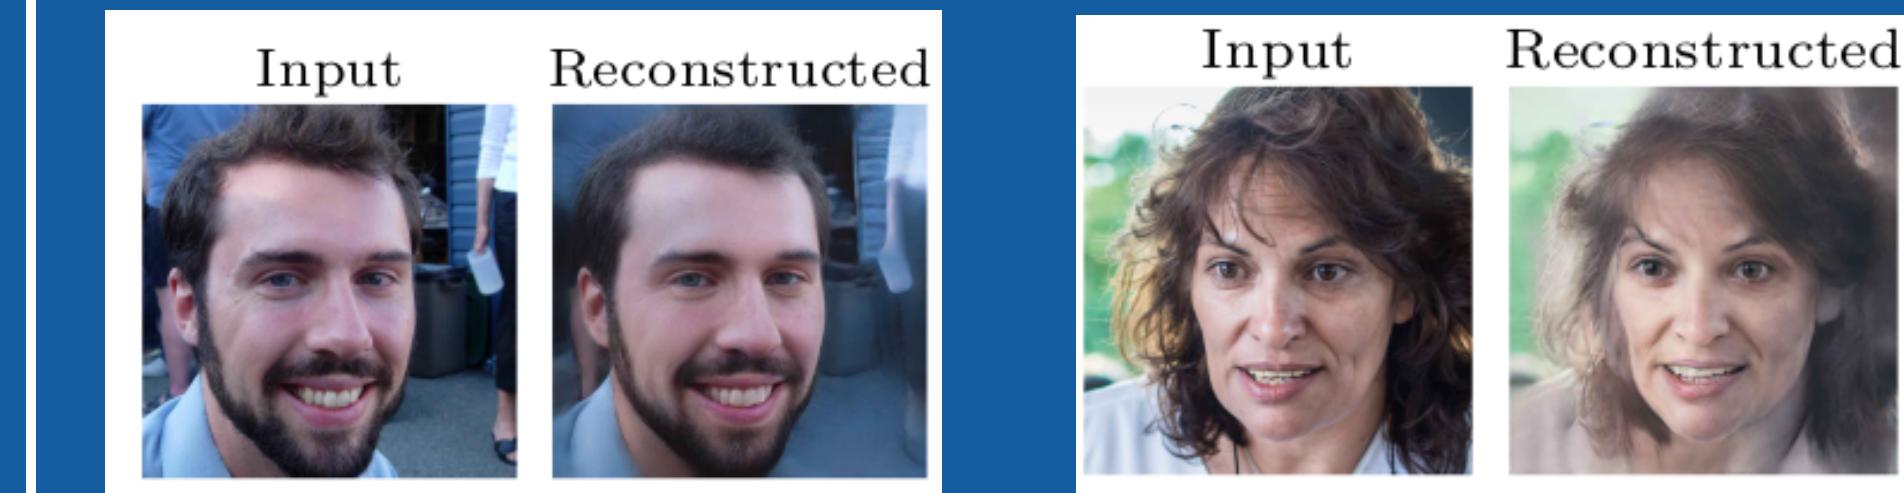
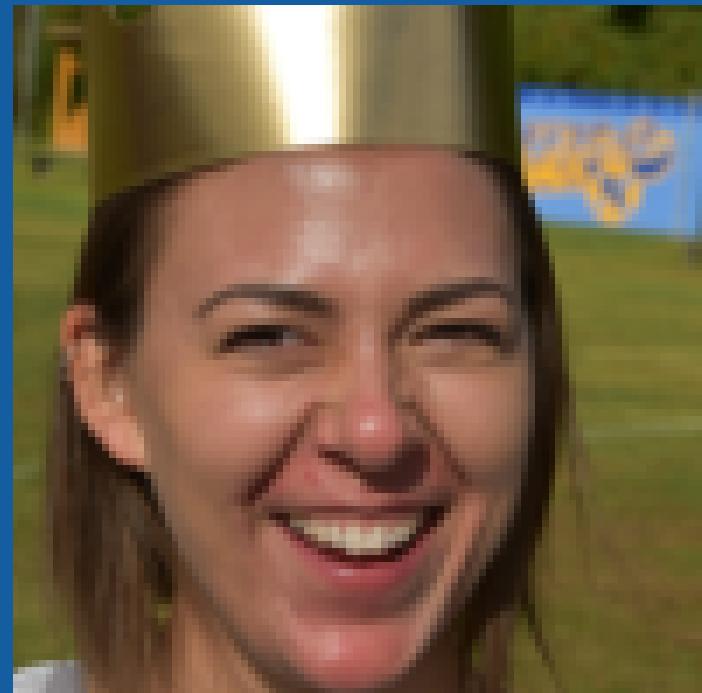


Fig. 2: Imagens reconstruídas via otimização de espaço latente

VISÃO GERAL

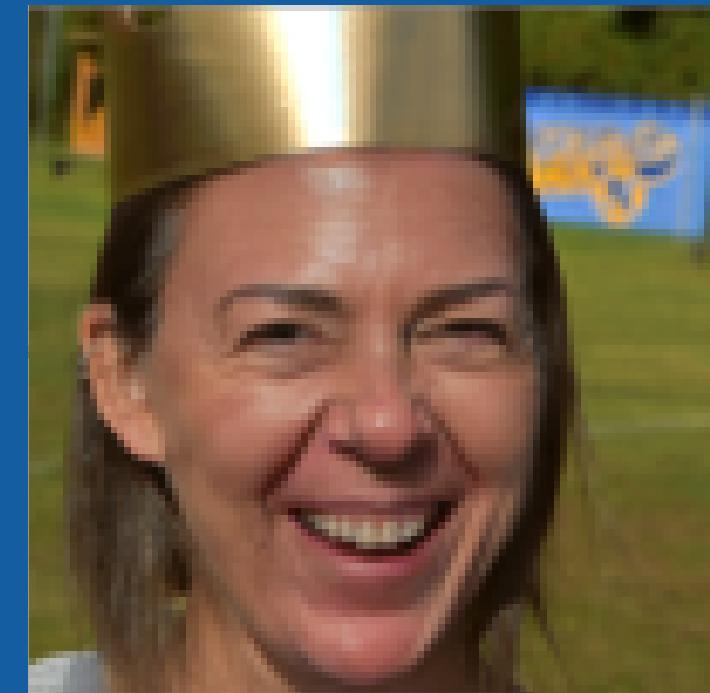


X_0

α_0



α_1



$G(X_0, \alpha_1)$

ARQUITETURA

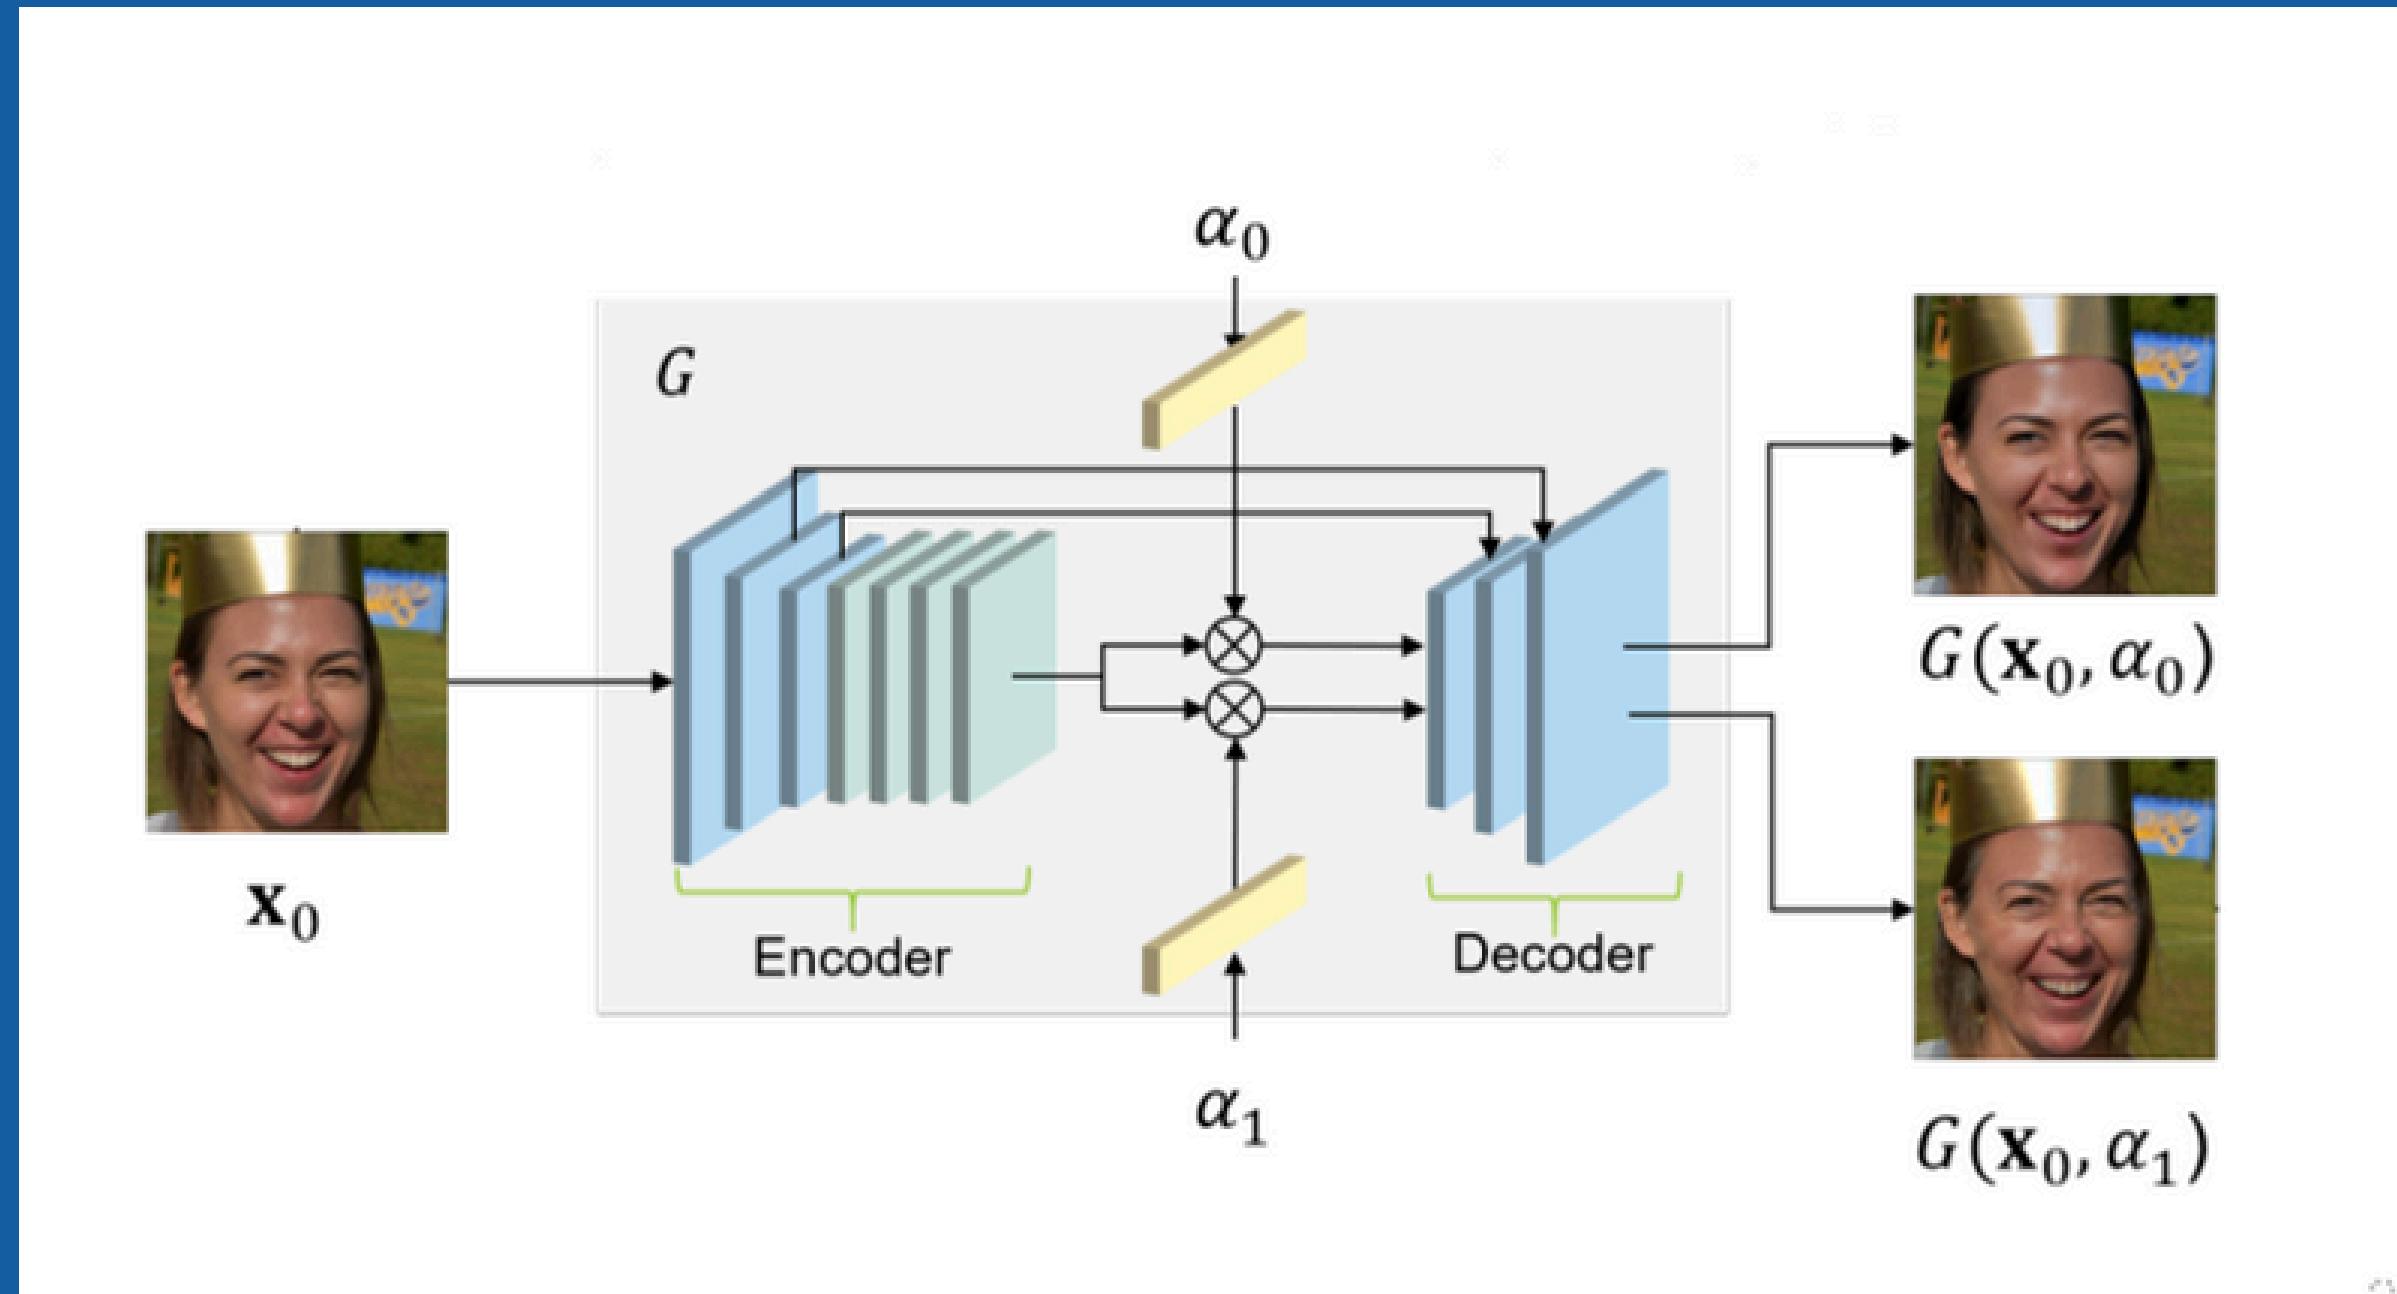


Fig. 3: Visão geral da arquitetura

TREINAMENTO

- ◆ A escolha de idades a no treinamento é feita respeitando uma diferença mínima de 25 anos
- ◆ Treinado na base de dados FFHQ com 70k amostras extraídas do Flickr
- ◆ StyleGAN é utilizado para balanceamento dos dados
- ◆ A faixa de idades é restrita entre 20 e 69 anos

FUNÇÕES DE PERDA

AGE CLASSIFICATION LOSS



Age Classifier
→

Probability Distribution
 $\{0, 1, \dots, 100\}$

X

a_1 one-hot vector

RECONSTRUCTION LOSS



MSE
→

$G(x_0, \alpha_o)$



x_0

FUNÇÕES DE PERDA

ADVERSARIAL LOSS

- ◆ Desenvolvida baseada em PatchGAN que divide e classifica a imagem em patches
- ◆ Utiliza o objetivo Least Square (LSGAN)
- ◆ Diferente de outros trabalhos, visa somente maximizar o fotorrealismo

$$\mathcal{L}_{\text{GAN}}(G) = \mathbb{E}_{\mathbf{x}_0 \sim p(\mathbf{x})} \mathbb{E}_{\alpha_1 \sim q(\alpha|\alpha_0)} [(D(G(\mathbf{x}_0, \alpha_1)) - 1)^2],$$

Generator

$$\mathcal{L}_{\text{GAN}}(D) = \mathbb{E}_{\mathbf{x}_0 \sim p(\mathbf{x})} \mathbb{E}_{\alpha_1 \sim q(\alpha|\alpha_0)} [(D(G(\mathbf{x}_0, \alpha_1)))^2] + \mathbb{E}_{\mathbf{y} \sim p(\mathbf{x})} [(D(\mathbf{y}) - 1)^2]$$

Discriminator

$$\mathcal{L} = \lambda_{\text{recon}} \mathcal{L}_{\text{recon}} + \lambda_{\text{class}} \mathcal{L}_{\text{class}} + \mathcal{L}_{\text{GAN}}$$

Total Loss

RESULTADOS

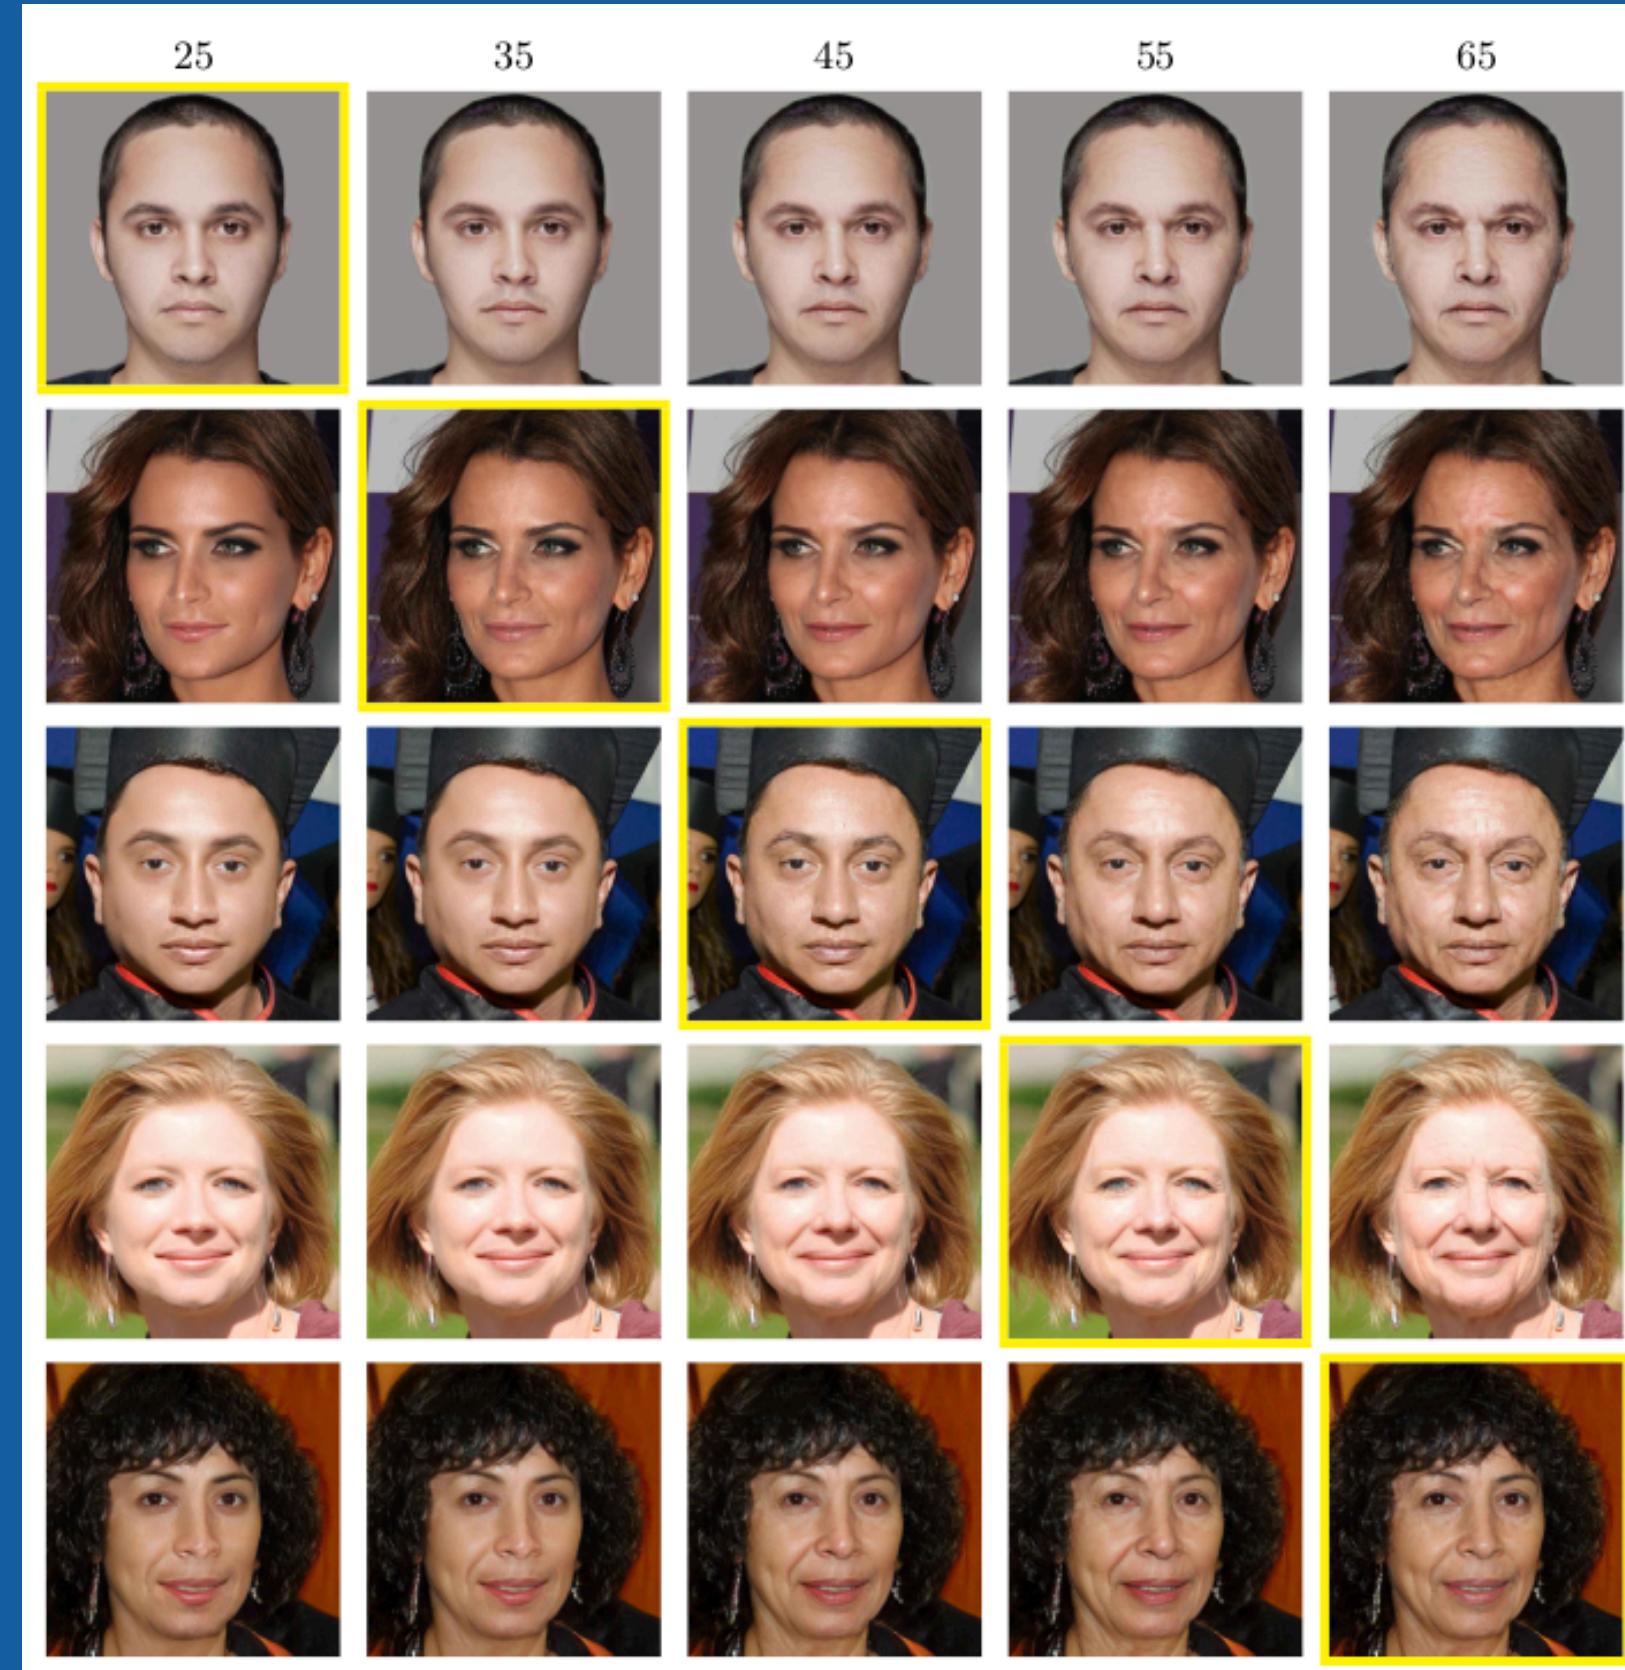


Fig. 4: Resultados 1024x1024

RESULTADOS

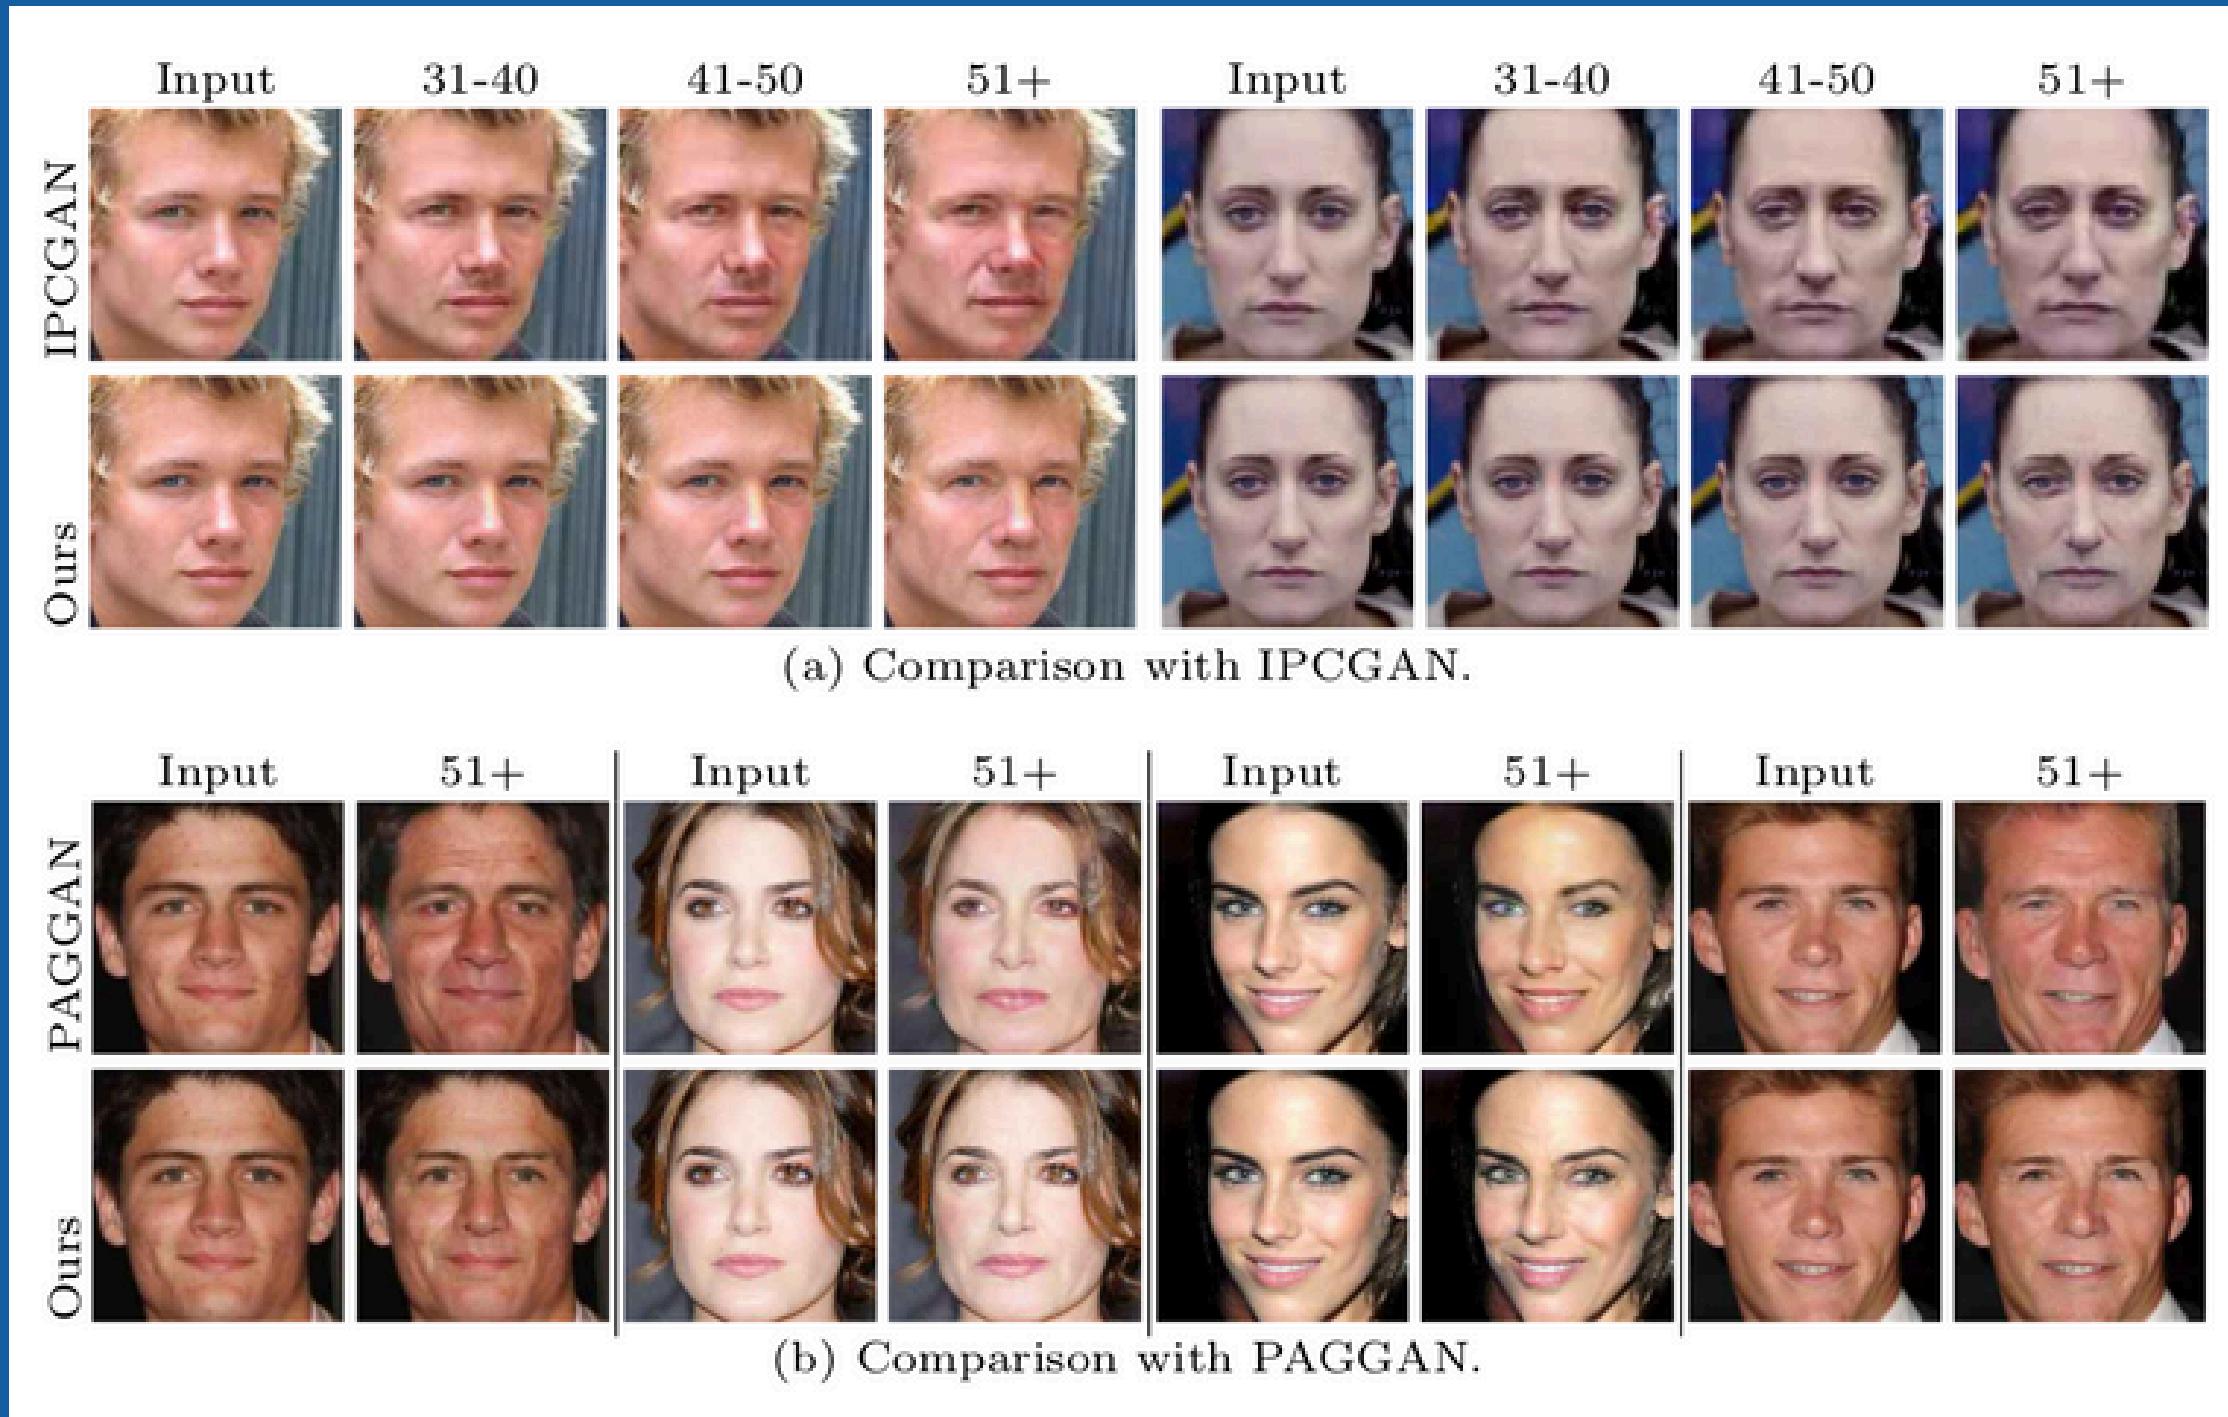


Fig. 5: Comparações com outros modelos no CACD

RESULTADOS

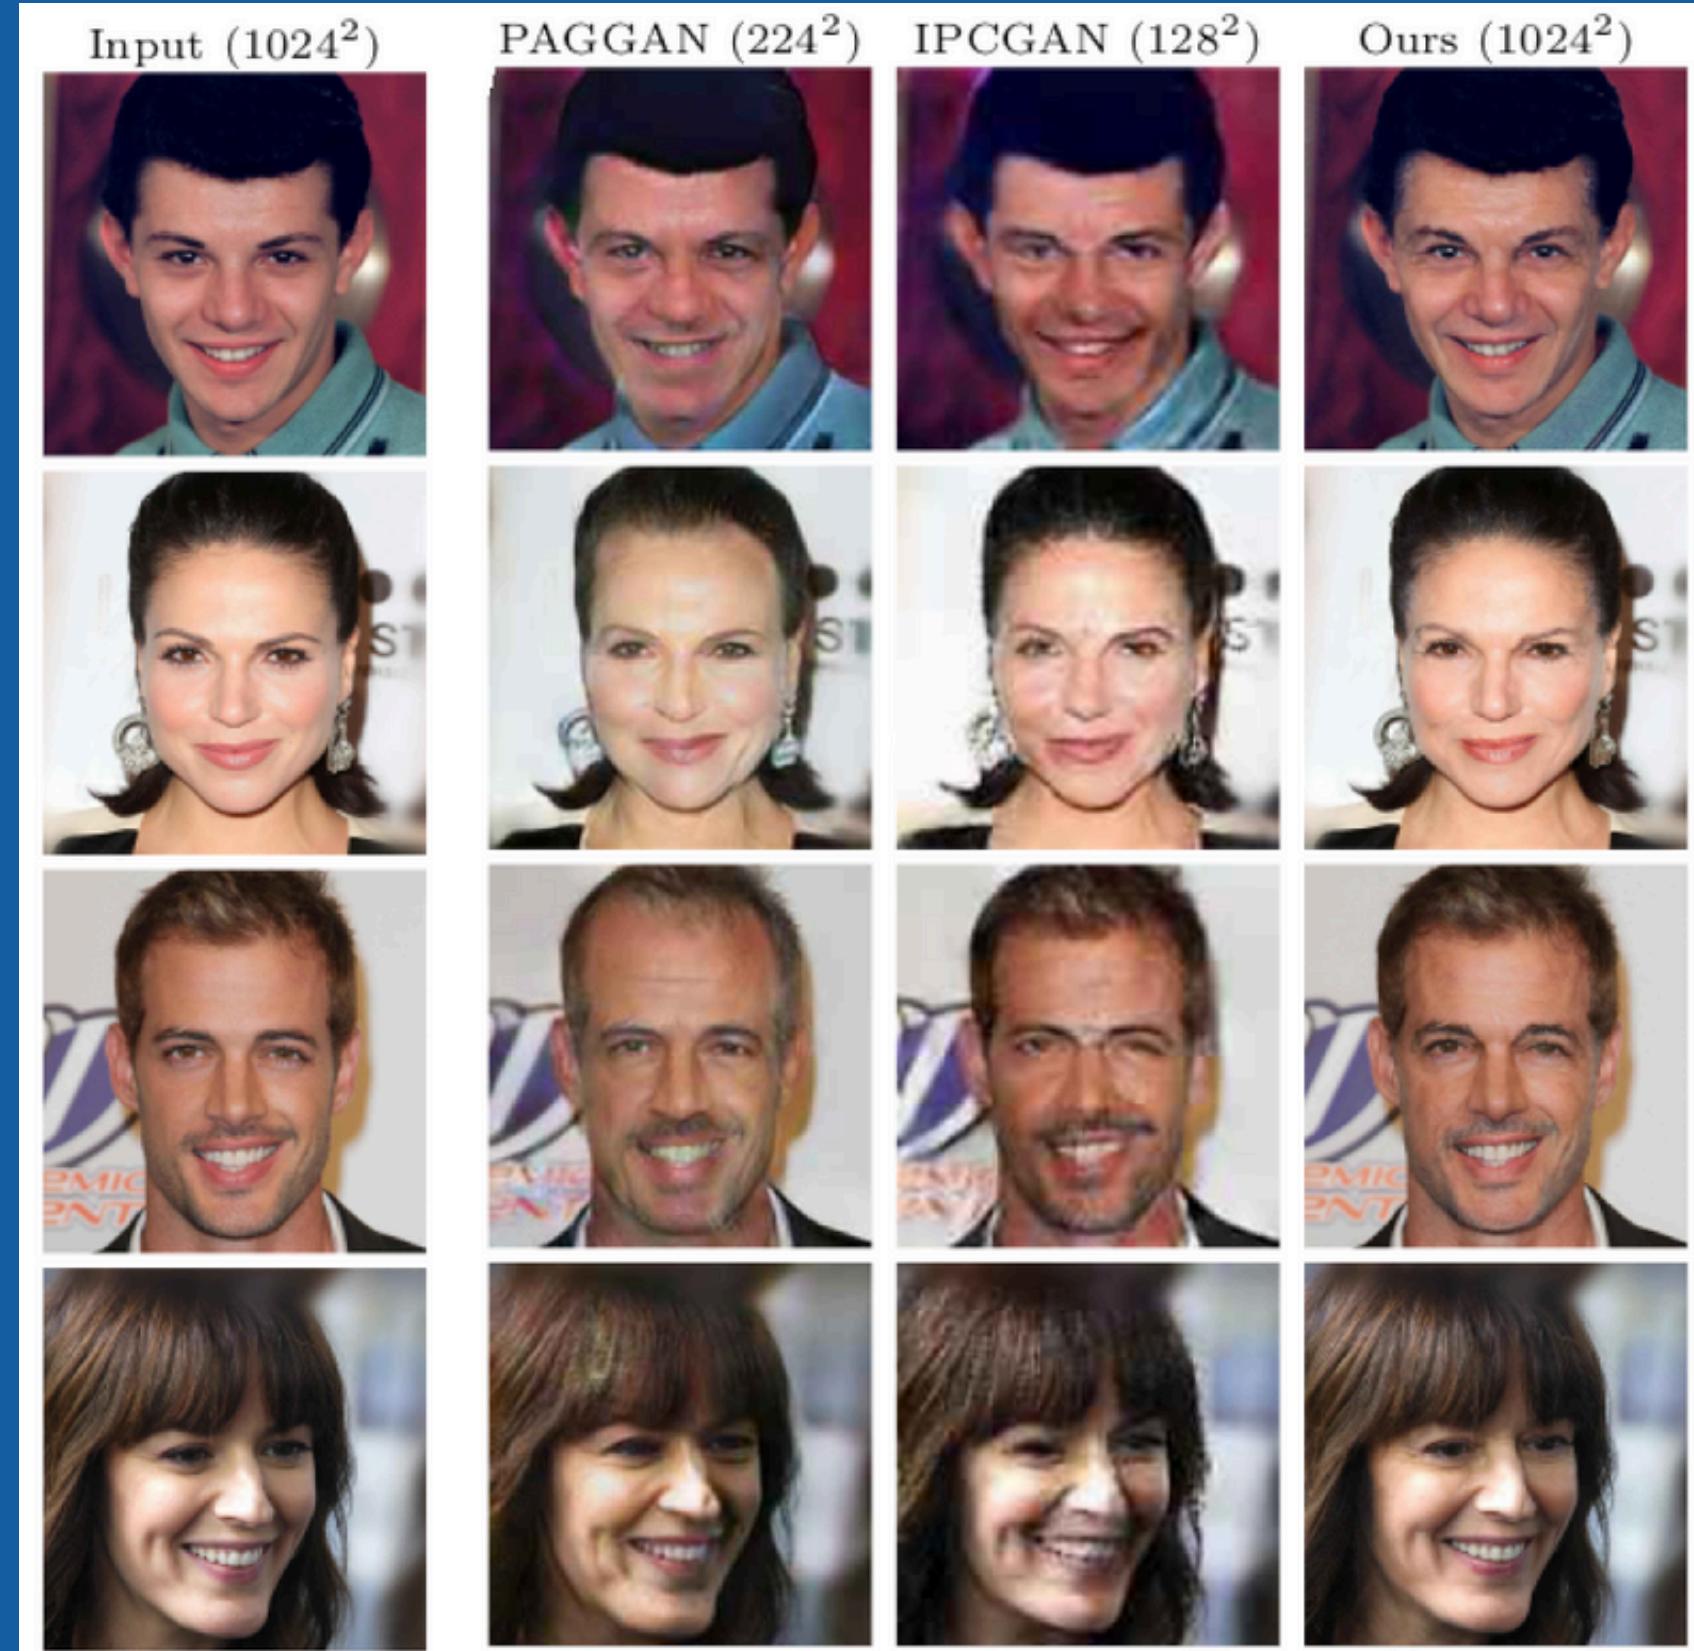


Fig. 6: Comparação com outra base de dados (CelebA-HQ)

RESULTADOS

| Method | Predicted Age | Blur | Gender Preservation(%) | Smiling | Emotion Preservation(%) | |
|---------------|-------------------|-------------|---------------------------|-----------------|-------------------------|--------------|
| | | | Preservation(%) | Preservation(%) | Neutral | Happiness |
| FaderNet [18] | 44.34 ± 11.40 | 9.15 | 97.60 | 95.20 | 90.60 | 92.40 |
| PAGGAN [38] | 49.07 ± 11.22 | 3.68 | 95.10 | 93.10 | 90.20 | 91.70 |
| IPCGAN [36] | 49.72 ± 10.95 | 9.73 | 96.70 | 93.60 | 89.50 | 91.10 |
| Ours | 54.77 ± 8.40 | 2.15 | 97.10 | 96.30 | 91.30 | 92.70 |

Tabela 1: Avaliação geral via Face++

DISCUSSÃO

Uso de diferentes tipos de discriminador

- ◆ Discriminador Condisional
- ◆ Dois discriminadores
- ◆ Abordagem proposta

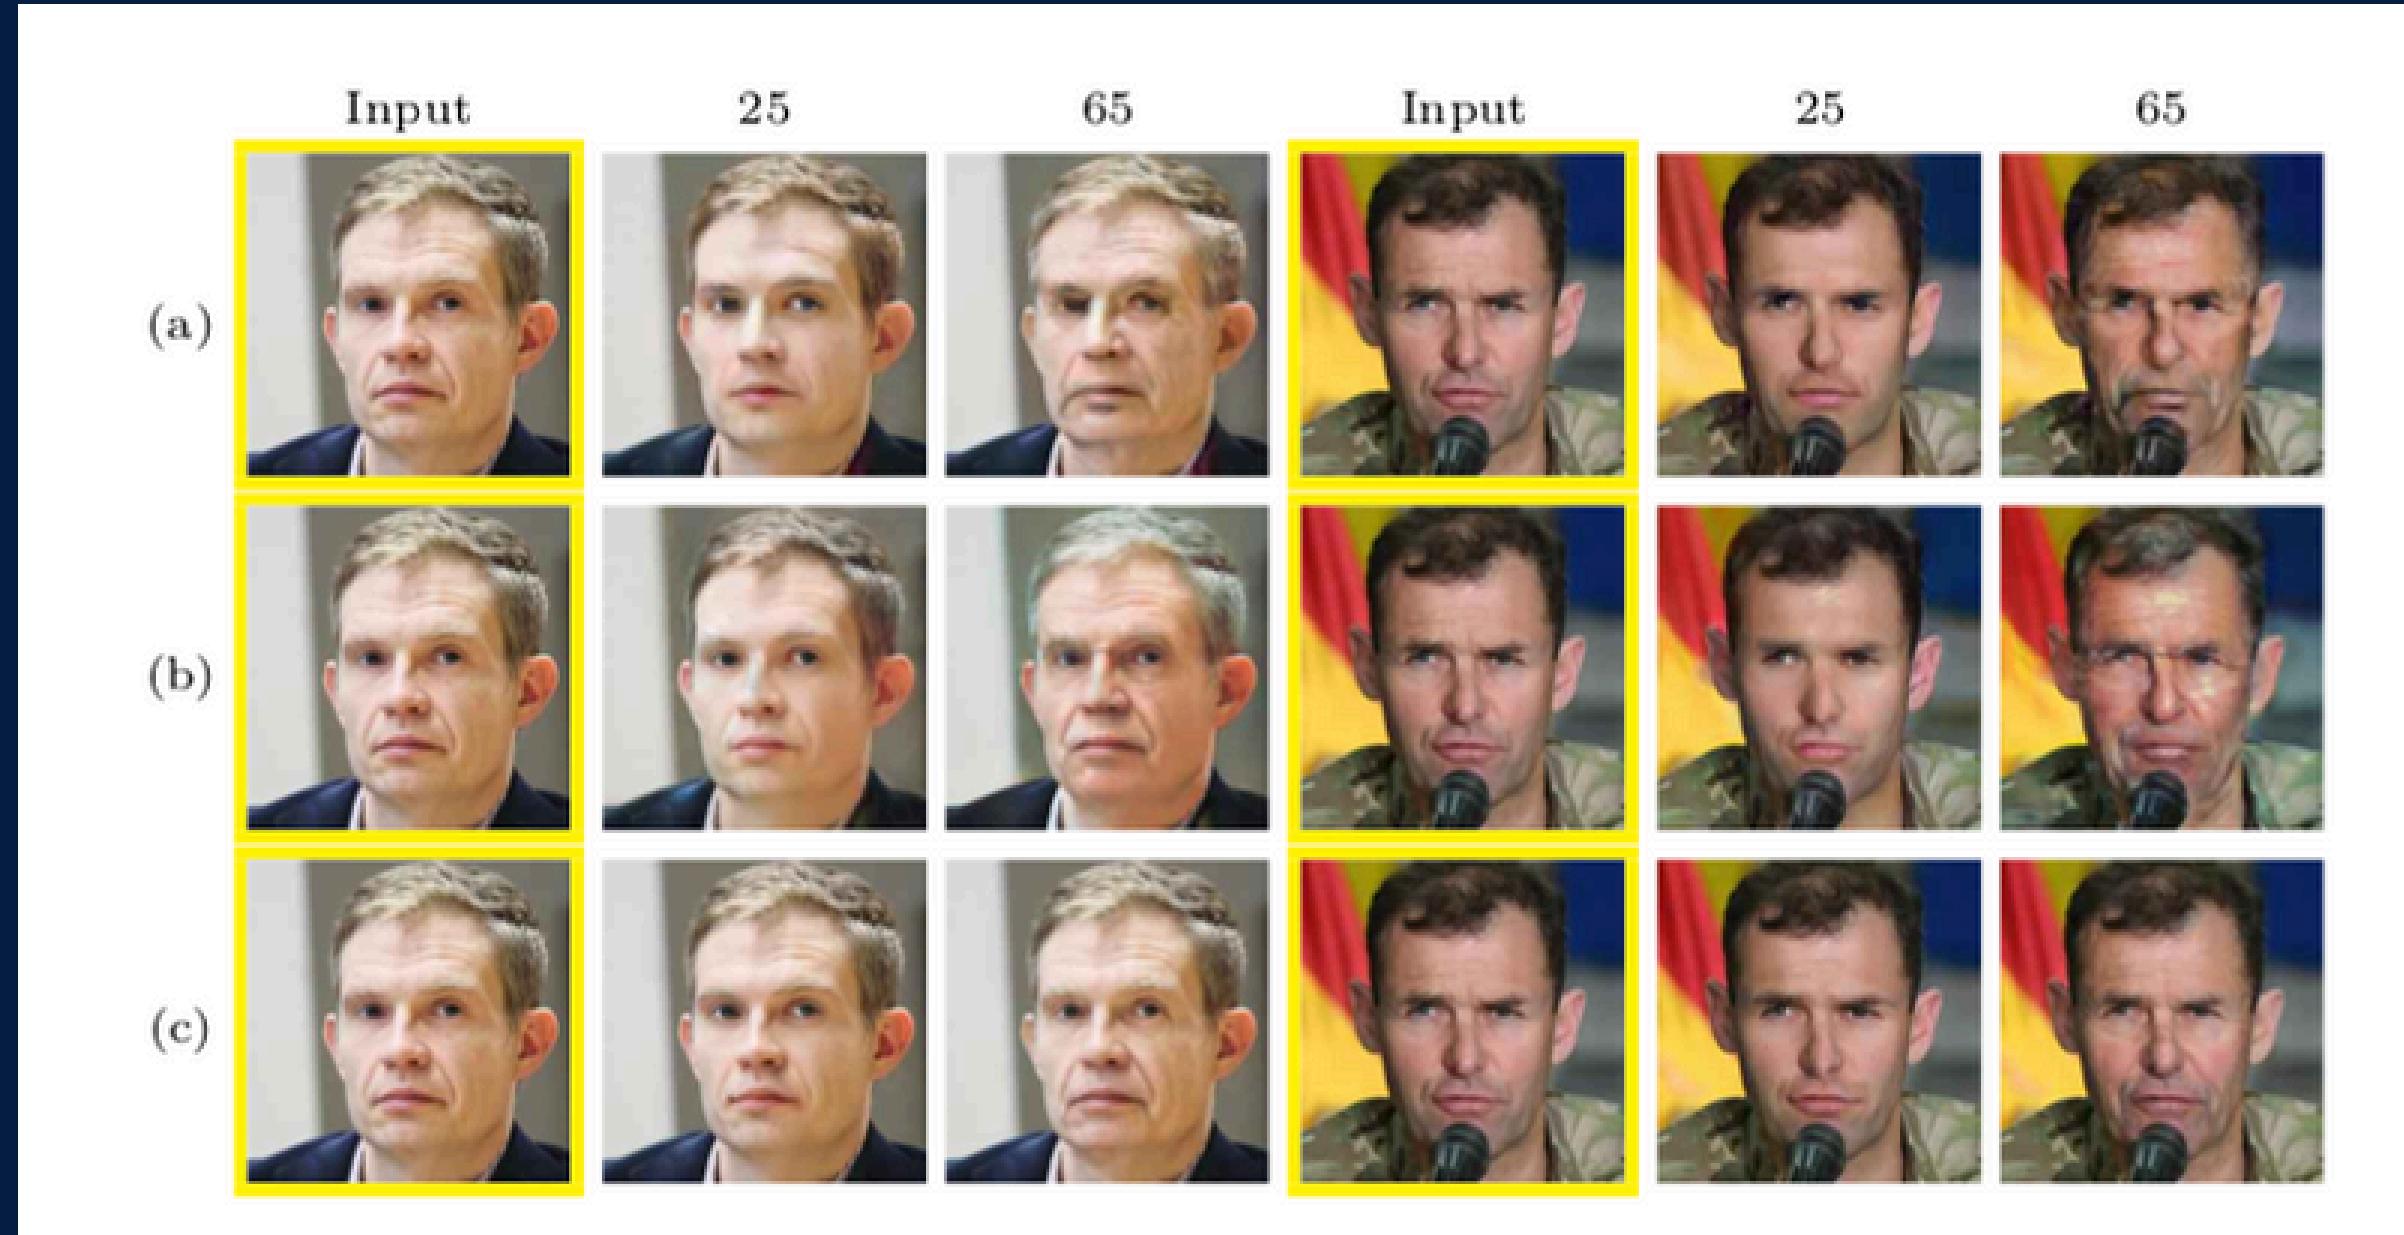


Fig. 7: Comparaçao entre diferentes tipos de discriminador

CONCLUSÃO

- ◆ HRFAE é um modelo de transformação de idade de arquitetura simples e competente, principalmente em alta resolução
- ◆ A inserção de um módulo de inserção de idade funciona muito bem
- ◆ Performance boa o suficiente para o uso em outras aplicações

CONCLUSÃO

- ◆ Abordagem de treinamento fracamente supervisionado pode ser bastante dependente do classificador de idade
- ◆ Treinamentos feitos em bases de dados de menores resoluções é pertinente
- ◆ Geração de bases de dados com maior variação de idade

Obrigado

Referência:

<https://arxiv.org/pdf/2005.04410>